PROJET DE RECHERCHE OPÉRATIONNELLE: TENSORFLOW APPLICATION classification de l'image

Bouslama. S\Mhiri. K10/12/2017



1 Introduction:

Depuis une dizaine d'années, les librairies et boîtes à outils informatiques destinées à l'intelligence artificielle se multiplient. Nous pouvons notamment citer Scikit-learn, sortie en 2010, qui est l'une des plus célèbres. Depuis, les acteurs majeurs de l'industrie ont décidé de créer et publier leurs propres librairies. TensorFlow est celle créée et rendue publique par Google en 2015. Utilisée entre autres par Ebay, Twitter, Airbus, AirBnb et Intel, cette librairie est performante et son avenir s'annonce prometteur. S'appuyer dessus semble donc être un choix tout à fait cohérent bien qu'il existe des alternatives sérieuses.

TensorFlow est un framework d'apprentissage en profondeur open source créé par Google qui donne aux développeurs un contrôle granulaire sur chaque neurone (connu sous le nom de «nœud» dans TensorFlow) afin que vous puissiez ajuster les poids et obtenir des performances optimales. TensorFlow a de nombreuses bibliothèques intégrées (dont peu seront utilisées pour la classification des images) et possède une communauté incroyable, vous pourrez donc trouver des implémentations open source pour pratiquement n'importe quel sujet d'apprentissage en profondeur.

Dans la suite, le type traité par TENSORFLOW est le CNN(Convolutional Neural Network) et plus précisément, l'exemple de la classification des images et leur recognition.

2 Principe de base du réseau de neurone convolutif :

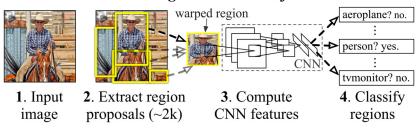
Les réseaux convolutifs sont une forme particulière de réseau neuronal multicouches dont l'architecture des connexions est inspirée de celle du cortex visuel des mammifères.

Leur conception suit la découverte de mécanismes visuels dans les organismes vivants. Ces réseaux de neurones artificiels (aussi baptisés réseau de neurones à convolution, ou CNN) sont capables de catégoriser les informations des plus simples aux plus complexes. Ils consistent en un empilage multicouche de neurones, des fonctions mathématiques à plusieurs paramètres ajustables, qui pré-traitent de petites quantités d'informations. Les réseaux convolutifs sont caractérisé par leurs premières couches convolutionelles (généralement une à trois). Une couche convolutive, est basée comme son nom l'indique sur le principe mathématique de convolution, et cherche à repérer la présence d'un motif (dans un signal ou dans une image par exemple).

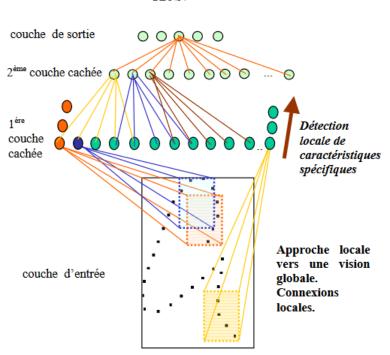
Pour une image, la première couche convolutionelle peut détecter les contours des objets (par exemple un cercle), la seconde couche convolutionelle peut combiner les contours en objets (par exemple une roue), et les couches suivantes (non nécessairement convolutionelles) peuvent utiliser ces informations pour distinguer une voiture d'une moto. Une phase d'apprentissage sur des objets connus

permet de trouver les meilleurs paramètres en montrant par exemple à la machine des milliers d'images d'un chien, d'une voiture ou d'un sport... L'un des enjeux est de trouver des méthodes pour ajuster ces paramètres le plus rapidement et le plus efficacement possible. Les réseaux neuronaux convolutifs ont de nombreuses applications dans la reconnaissance d'images, de vidéos ou le traitement du langage naturel. Parmi eux on cite la classification des images.

R-CNN: Regions with CNN features



TDNN



3 la classification et la recognition de l'image :

3.1 definition:

Comme son nom l'indique, la classification s'agit d'une opération visant à classer les images en fonction des sujets, décors, actions ou toutes autres propriétés visibles sur les images. Cette opération correspond à un besoin réel de l'industrie. Nous pouvons citer notamment la modération automatisée d'images de profil, le contrôle parental ou encore la détection d'événements anormaux de toutes sortes.

3.2 comment cela fonctionne:

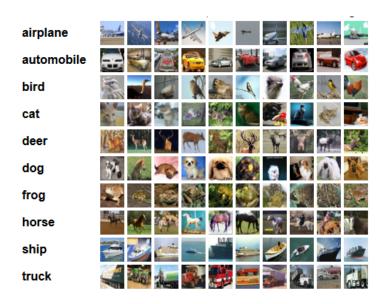
Grâce à tensorflow, un ordinateur est désormais capable de detecter l'aspect d'une image et dire avec un pourcentage d'erreur minimal ce que représente cette derniere en contenu. Pour ce faire, nous devons d'abord apprendre à l'ordinateur à quoi ressemble un chat, un chien, un oiseau, etc. avant qu'il ne puisse reconnaître un nouvel objet. Plus l'ordinateur voit de chats, mieux il reconnaît les chats. Ceci est connu comme l'apprentissage supervisé. Nous pouvons effectuer cette tâche en étiquetant les images, l'ordinateur commencera à reconnaître les motifs présents dans les images de chat qui sont absents des autres et commencera à construire sa propre cognition

3.3 introduction de la dataset

L'ensemble de données CIFAR-10 se compose de 60000 images couleur 32x32 dans 10 classes, avec 6000 images par classe. Il y a 50000 images d'entraînement et 10000 images d'essai.

L'ensemble de données est divisé en cinq lots de formation et un lot de test, chacun avec 10000 images. Le lot de test contient exactement 1000 images sélectionnées au hasard dans chaque classe. Les lots d'entraînement contiennent les images restantes dans un ordre aléatoire, mais certains lots d'entraînement peuvent contenir plus d'images d'une classe que d'une autre. Entre eux, les lots d'entraînement contiennent exactement 5000 images de chaque classe.

Voici les classes dans l'ensemble de données, ainsi que 10 images aléatoires de chacun :



3.4 codage et démarche :

1-Obtenir les données :

```
self.total = total_size
    self.update((block_num - self.last_block) * block_size)
    self.last_block - block_num

if not isfile('cifar-10-python.tar.gz'):
    with DlProgress(unit-'b', unit_scale=True, miniters=1, desc-'CIFAR-10 Dataset') as pbar:
    urlnetrieve(
        'nttps://www.cs.toronto.edu/~kriz/cifar-10-python.tar.gz',
        'cifar-10-python.tar.gz',
        pbar.hook)

if not isdir(cifari0_dataset_folder_path):
    with tarfile.open('cifar-10-python.tar.gz') as tar:
        tar.extractall()
    tar.close()

tests.test_folder_path(cifari0_dataset_folder_path)

All files found!
```

$2\text{-}\mathrm{Explorer}$ les données :

```
In [2]: %matplotlib inline
%config InlineBackend.figure_format = 'retina'
import helper
import numpy as np

# Explore the dataset
batch_id = 1
sample_id = 5
helper.display_stats(cifar10_dataset_folder_path, batch_id, sample_id)
```

 $3\mbox{-}\mathrm{Implémenter}$ les fonctions de préprocès :

-Normaliser

-Applatir la couche

```
In [9] def figure(n_troop)

In state of the first of the
```

4-Convolution et couche de regroupement maximum

-Applatir la couche

-Couche entièrement connectée

Fully-Connected Layer

Implement the fully_conn function to apply a fully connected layer to x_tensor with the shape (Batch Size, num_outputs). Shortcut option: you can use classes from the IensorFlow Layers (contrib) packages for this layer. For more of a challenge, only use other TensorFlow packages.

```
In [18]: def fully_conn(x_tensor, num_outputs):

Apply a fully connected layer to x_tensor using weight and bias
: x_tensor: A 2-D tensor where the first dimension is batch size.
: num_outputs: The number of output that the new tensor should be.
: return: A 2-D tensor where the second dimension is num_outputs.

# TODO: ImpLement Function

num_in - x_tensor.get_shape().as_list()[1]
weights = tf.Variable(tf.random_normal([num_in, num_outputs]))
bias = tf.Variable(tf.random_normal([num_in, num_outputs]))
fully_conn - tf.add(tf.matmul(x_tensor, weights), bias)

fully_conn - tf.nn.relu(fully_conn)

return fully_conn

OON'T MODIFY ANYTHING IN THIS CELL THAT IS BELOW THIS LINE

tests.test_fully_conn(fully_conn)

Tests Passed
```

-Couche de sortie

```
Output Layer

Imperment the cutput function to apply a fully connected tope to x_tensor with the shape (Bato Size, num_output). Shortful option; you can use classes from the liminations.Lighted to imperment the liminations.Lighted to imperment the liminations of imperment to the liminations of imperment to the liminations. More Activation, software, or case entropy about not be applied to this.

In [11]:

In [12]:

In [13]:

In [13]:

In [14]:

In [15]:

In [15]:

In [16]:

In [16]
```

5-Créer un modèle convolutif :

```
In [12]: def conv_net(x, keep_prob):
                   Create a convolutional neural network model

ix: Placeholder tensor that holds image data.

keep_prob: Placeholder tensor that hold dropout keep probability.

return: Tensor that represents logits
                    # TODO: Apply J, 2, or 3 Convolution and Max Pool Layers
# Play around with different number of outputs, hermel size and stride
# Function Definition from Above:
# com72 mappool[r_temion; com_mm_outputs, com_whize, com_strides, pool_ksize, pool_strides)
                           # Variable initialization
conv_ksize = (3, 3)
conv_strides = (2, 2)
pool_ksize = (2, 2)
pool_strides = (1, 1)
conv_num_outputs = 48
                            # CNN layer 1 -- 32x32x3 to 16x16x48 conv_layer = conv2d_maxpool(x, conv_num_outputs, conv_ksize, conv_strides, pool_ksize, pool_strides)
                            # CNN layer 2 -- 16x16x48 to 8x8x192 conv_layer = conv2d_maxpool(conv_layer, 192, (2, 2), conv_strides, pool_ksize, (1, 1))
                            # CNN layer 3 -- 8x8x192 to 4x4x384 conv_layer = conv2d_maxpool(conv_layer, 384, (2, 2), conv_strides, (1, 1), pool_strides)
                             # CNN Layer 4 - 4x4x384 to 2x2x512
conv_layer = conv2d_maxpool(conv_layer, 512, (2, 2), (2, 2), (1, 1), (1, 1))
                           # 2x2x512 to 2048
conv_layer = flatten(conv_layer)
                            # TODO: Apply 1, 2, or 3 Fully Connected Layers
# Play around with different number of outputs
# Function Definition from Above:
# fully_conn(x_tensor, num_outputs)
                               # Dropout -- 3072 to (keep_prob * 3072)
fully_conn_layer = tf.nn.dropout(conv_layer, keep_prob)
                               # Fully connected layer 1 -- (keep_prob * 3072) to 512 fully_conn_layer = fully_conn(conv_layer, 512)
                               # Fully connected layer 2 -- 512 to 128
fully_conn_layer = fully_conn(fully_conn_layer, 128)
                               # TODO: Apply an Output Layer
# Set this to the number of classes
# Function Definition from Above:
# output(x_tensor, num_outputs)
                               # Output layer -- 128 to 10
out = output(fully_conn_layer, 10)
                               # TODO: return output return out
```

6-Former le réseau neurone :

$7 ext{-Afficher la statistique}:$

```
In [14] and going nitrocolousine, foreignated, limit, label, label, ander, someway)

prior information must lass and validation entering

in the later process and on large large data

in the later process and on large large data

in continuous later and later later later

in continuous later later later later later

in continuous later later later later

in continuous later later later later later

in continuous later later later later later later

in continuous later late
```

8-Former sur un seul lot CIFAR-10:

```
In []:

"""

ONT MODIFY ANYTHING IN THIS CELL

print('Checking the Training on a Single Batch...')

with it's session() as sess:

""" Intituiting the veriables

sess.run(ff,global_variables.initializer())

""" Training orice

for printing orice

for epoch in range(spochs):

batch, i """

for batch, i """ Intituiting the session of the
```

-Former comletement le modele

Fully Train the Model

Now that you got a good accuracy with a single CIFAR-10 batch, try it with all five batches.

9-Tester le modele :

Test Model ¶

Test your model against the test dataset. This will be your final accuracy. You should have an accuracy greater than 50%. If you don't, keep tweaking the model architecture and parameters.

```
def test_model():
    Test the saved model against the test dataset
    """

test_features, test_labels = pickle.load(open('preprocess_training.p', mode='rb'))
loaded_graph = tf.Gnaph()

with tf.Session(graph=loaded_graph) as sess:
    # Load model
loader = tf.train.import_meta_graph(save_model_path + '.meta')
loaded.restore(sess, save_model_path)

# Get Tensors from Loaded model
loaded_x = loaded_graph.get_tensor_by_name('x:0')
loaded_x = loaded_graph.get_tensor_by_name('x:0')
loaded_keep_prob = loaded_graph.get_tensor_by_name('keep_prob:0')
loaded_logits = loaded_graph.get_tensor_by_name('keep_prob:0')
loaded_logits = loaded_graph.get_tensor_by_name('accuracy:0')

# Get accuracy in batches for memory Limitations
test_batch_acc_total = o

test_batch_acc_total = sess.run(
loaded_acc_total = sess.run(
loaded_acc_
```

4 Conclusion:

Nous avons été en mesure de construire un réseau de neurones convolutionnels artificiels qui peut reconnaître des images avec une précision entre 50% et 70% en utilisant TensorFlow. Nous l'avons fait en prétraitant les images pour rendre le modèle plus générique, diviser l'ensemble de données en un certain nombre de lots et finalement construire et former le modèle.